

Analisi Statistica dei Fattori Latenti del disturbo dello spettro autistico

Victor Hugo Cascone e Paolo Primitivo

September 11, 2026

Abstract

Il presente lavoro analizza un dataset relativo a strumenti di screening e valutazione dei tratti dello spettro autistico, con l'obiettivo di individuare le variabili e i costrutti latenti maggiormente associati alla classificazione dei soggetti con e senza tratti ASD. Viene inizialmente stimato un modello completo, poi nella seconda parte del lavoro vengono confrontati tre modelli che differiscono tra di loro per metodo di selezione della variabili utilizzato. Il primo modello utilizza l'algoritmo boruta, il secondo un LASSO, il terzo un metodo di riduzione della dimensionalità. L'analisi comparativa mette in luce implicazioni interpretative e prestazionali dei diversi metodi.

1 Introduzione e Contesto

L'ASD (Autism spectrum disorders o disturbo dello spettro autistico) rappresenta un disturbo del neurosviluppo caratterizzato da difficoltà persistenti nella comunicazione e nell'interazione sociale, associate alla presenza di comportamenti, interessi o attività ristretti e ripetitivi [1]. Una diagnosi precoce consente di avviare tempestivamente interventi terapeutici e riabilitativi, migliorando significativamente la qualità della vita dei pazienti e delle loro famiglie. Il dataset utilizzato in questo studio è costituito da dati clinici e comportamentali raccolti nell'ambito dello screening dei disturbi dello spettro

autistico attraverso l'AQ10, un questionario che i medici di base possono utilizzare per valutare se una persona debba essere indirizzata a una valutazione per l'autismo [2]. L'obiettivo principale del dataset è supportare lo sviluppo e la valutazione di modelli di classificazione in grado di identificare la presenza di tratti riconducibili allo spettro autistico attraverso l'integrazione di informazioni demografiche, anamnestiche, cliniche e derivate da strumenti di screening standardizzati. Le diagnosi di disturbo dello spettro autistico presentano molte comorbidità quali depressione, disturbo d'ansia e deficit del linguaggio [1]. Le informazioni disponibili consentono sia un'analisi descrittiva delle caratteristiche del campione sia l'applicazione di tecniche di machine learning finalizzate all'identificazione delle variabili maggiormente associate alla presenza di tratti autistici e alla costruzione di modelli predittivi.

2 Descrizione del Dataset

Il dataset proviene da Kaggle [5] e comprende 1985 osservazioni e 28 variabili, relative a soggetti sottoposti a procedure di screening e contiene variabili eterogenee, comprendenti informazioni anagrafiche, condizioni mediche pregresse, disturbi del neurosviluppo e punteggi ottenuti mediante altri questionari clinici validati. Le variabili sono di natura continua e binaria, mentre la variabile target è rappresentata dalla presenza o assenza di tratti dello spettro autistico (ASD traits), configurando quindi un problema di classificazione binaria.

Le variabili presenti nel dataset includono:

- CASE.NO.PATIEN'T - Numerica - Identificativo del paziente
- A1 - Binaria - Prima domanda del questionario AQ10 (Si/No).
- A2 - Binaria - Seconda domanda del questionario AQ10 (Si/No).
- A3 - Binaria - Terza domanda del questionario AQ10 (Si/No).
- A4 - Binaria - Quarta domanda del questionario AQ10 (Si/No).
- A5 - Binaria - Quinta domanda del questionario AQ10 (Si/No).
- A6 - Binaria - Sesta domanda del questionario AQ10 (Si/No).
- A7 - Binaria - Settima domanda del questionario AQ10 (Si/No).

- A8 - Binaria - Ottava domanda del questionario AQ10 (Si/No).
- A9 - Binaria - Nona domanda del questionario AQ10 (Si/No).
- A10 Autism Spectrum Quotient - Binaria - Punteggio del questionario AQ10 (Si/No).
- Social Responsiveness Scale - Numerica - Punteggio di reattività sociale
- Age years - Numerica - Età del soggetto espressa in anni.
- Qchat 10 Score - Numerica - Punteggio finale del test Quantitative Checklist for Autism in Toddlers.
- Speech.Delay.Language.Disorder - Binaria - Presenza di disturbi dello sviluppo del linguaggio (Si/No)
- Learning.disorder - Binaria - Presenza di disturbo dell'apprendimento (Si/No)
- Genetic Disorders - Binaria - Presenza di malattie genetiche (Si/No)
- Depression - Binaria - Presenza di depressione (Si/No)
- Global.developmental.delay.intellectual.disability - Binaria - Presenza di ritardo globale dello sviluppo e disabilità intellettiva (Si/No)
- Social.Behavioural.Issues - Binaria - Presenza di disturbi del comportamento (Si/No)
- Childhood.Autism.Rating.Scale - Numerica - Punteggio di valutazione autismo infantile
- Anxiety Disorders - Binaria - Presenza di disturbi d'ansia (Si/No)
- Sex - Categorica (binaria) - Sesso biologico del soggetto (Maschio/Femmina).
- Ethnicity - Categorica - Etnia del soggetto partecipante.
- Jaundice - Binaria - Presenza di ittero neonatale (Si/No)
- Family members with ASD - Binaria - Presenza di soggetti con ASD all'interno della famiglia (Si/No)
- Who completed the test - Categorica - Chi ha completato il test
- ASD traits - Binaria - Presenza di tratti del disturbo dello spettro autistico.

3 Fase Esplorativa

Sono presenti 48 missing values nel dataset di cui 39 della variabile QCHAT 10 SCORE e 9 in Social responsiveness scale. Sono state quindi eliminate le osservazioni che presentavano dati mancanti.




Figure 1: Barplot ASD

L'analisi descrittiva delle variabili binarie evidenzia una distribuzione relativamente equilibrata per la maggior parte delle caratteristiche cliniche considerate. In particolare, il 54,1% dei soggetti presenta un ritardo o un disturbo del linguaggio (Speech Delay/Language Disorder), mentre il 54,9% manifesta un disturbo dell'apprendimento (Learning Disorder). La presenza di disturbi genetici è stata riscontrata nel 51,9% del campione.

Per quanto riguarda le comorbidità psichiatriche, il 53,9% dei soggetti presenta diagnosi di depressione, mentre il 53,8% presenta un disturbo d'ansia. Analogamente, il 53,9% dei partecipanti mostra un ritardo globale dello sviluppo o una disabilità intellettiva, e il 53,2% presenta problematiche sociali o comportamentali.

La variabile relativa all'ittero neonatale (Jaundice) risulta essere la più frequente nel campione, essendo presente nel 77,2% dei soggetti. Al contrario, la presenza di un familiare

con diagnosi di disturbo dello spettro autistico (Family member with ASD) caratterizza il 31,7% dei partecipanti, rappresentando la variabile con la minore prevalenza.

L'analisi della distribuzione della variabile Age Years evidenzia una distribuzione non normale e caratterizzata da una certa eterogeneità. In particolare, si osservano alcune concentrazioni di osservazioni nelle fasce di età comprese tra 6 e 8 anni e tra 12 e 14 anni, suggerendo una distribuzione multimodale.



Figure 2: Istogramma Age_years

Per quanto riguarda la variabile target, si presenta abbastanza equilibrata.

- 0 (non presenza ASD traits) = 908 - 47%
- 1 (presenza ASD traits) = 1029 - 53%




Figure 3: Age rispetto ad ASD_traits

Il boxplot che confronta gli esiti della variabili ASD in base all'età risultano pressoché identici, infatti la mediana è la stessa (9 anni) tra i soggetti con e senza tratti dello spettro autistico, così come l'intervallo interquartile e la dispersione complessiva dei dati. Non emergono quindi differenze sostanziali nella distribuzione dell'età tra le due classi, suggerendo che questa variabile possa avere un potere discriminante limitato rispetto alla presenza di tratti ASD.

3.1 Data leakage

Data la natura predittiva di alcune variabili del dataset, é sembrato utile confrontare un modello comprendente di tutte le variabile e un secondo modello privato delle prime 10 variabili del dataset ovvero l'identificativo del paziente, le domande del questionario, il risultato del questionario, la variabile social responsivness scale e infine la variabile Childhood Autism Rating Scale. L'ipotesi è che includere nel modello predittivo degli item che sono, di fatto, proxy diretti della diagnosi clinica (o che derivano dagli stessi test di screening) rende il modello tautologico.

3.2 Matrice di correlazione

Al fine di esplorare le relazioni esistenti tra le variabili del dataset, è stata costruita una matrice di correlazione utilizzando il coefficiente di Pearson. Considerata la prevalenza di variabili binarie, i coefficienti ottenuti devono essere interpretati principalmente come misure di associazione tra le caratteristiche cliniche e comportamentali considerate.

La matrice di correlazione evidenzia la presenza di associazioni moderate ed elevate tra le variabili derivanti dagli strumenti di screening dell'autismo (AQ-10, QCHAT-10, Social Responsiveness Scale e Childhood Autism Rating Scale) e la variabile target ASD_traits. In particolare, le domande A1-A10 mostrano una forte correlazione reciproca, suggerendo la presenza di una significativa ridondanza informativa. Le variabili cliniche relative ai disturbi del neurosviluppo, ai disturbi d'ansia e ai disturbi dell'apprendimento presentano correlazioni positive moderate con la presenza di tratti ASD, mentre la variabile relativa al sesso biologico mostra associazioni lineari relativamente deboli. Tali evidenze suggeriscono la possibile presenza di fenomeni di multicollinearità e hanno motivato la costruzione di un secondo dataset privo delle principali scale diagnostiche.

L'analisi della matrice di correlazione evidenzia la presenza di numerose associazioni positive tra le variabili del dataset. In particolare, le variabili relative ai disturbi del neurosviluppo e alle condizioni cliniche associate mostrano coefficienti di correlazione particolarmente elevati. Le associazioni più intense sono state osservate tra le variabili Speech Delay/Language Disorder e Learning Disorder ($r = 0.98$), nonché tra Depression e Anxiety Disorder ($r = 0.99$), suggerendo la presenza di una forte dipendenza strutturale tra tali caratteristiche nel campione analizzato.

Un'ulteriore osservazione si può fare attraverso i conteggi




Figure 4: Matrice correlazione dataset intero




Figure 5: Matrice correlazione dataset ridotto

Figure 6: Tabella di contingenza tra Speech Delay/Language Disorder e Learning Disorder

	Learning Disorder = 0	Learning Disorder = 1
Speech Delay = 0	873	16
Speech Delay = 1	0	1048

Figure 7: Tabella di contingenza tra Depression e Anxiety Disorder

	Anxiety Disorder = 0	Anxiety Disorder = 1
Depression = 0	892	0
Depression = 1	3	1042

La variabile Family member with ASD presenta una correlazione positiva moderata con la variabile target ASD_traits ($r = 0.26$), indicando una possibile associazione tra familiarità e presenza di tratti dello spettro autistico. Analogamente, le variabili relative ai disturbi del neurosviluppo, ai disturbi dell'apprendimento e alle problematiche comportamentali mostrano correlazioni positive moderate con la variabile target (r compreso tra 0.33 e 0.35), suggerendo un potenziale contributo predittivo.

Al contrario, la variabile Age_Years presenta correlazioni deboli con la maggior parte delle variabili considerate e una correlazione pressoché nulla con la variabile target ($r = -0.02$), suggerendo un limitato potere discriminante in un'analisi univariata.

Nel complesso, la matrice di correlazione evidenzia la presenza di una significativa ridondanza informativa tra alcune variabili cliniche. Tale risultato suggerisce la possibile presenza di fenomeni di multicollinearità, che saranno successivamente approfonditi mediante l'analisi del Variance Inflation Factor (VIF) e affrontati attraverso tecniche di selezione delle variabili.

3.3 Test Chi quadro

Al fine di valutare l'associazione tra le variabili categoriche considerate e la presenza di tratti dello spettro autistico (ASD_traits), è stato applicato il test del chi-quadro di indipendenza. I risultati hanno evidenziato come la maggior parte delle variabili analizzate presenti una relazione statisticamente significativa con la variabile target.

In particolare, le associazioni più elevate sono state osservate per il sesso biologico ($\chi^2 = 331.18, p < 0.001$) e per le variabili cliniche e neuroevolutive, quali Speech Delay/Language Disorder ($\chi^2 = 202.42$), Anxiety Disorder ($\chi^2 = 200.34$), Learning Disorder ($\chi^2 = 193.45$) e Genetic Disorders ($\chi^2 = 183.67$), tutte con valori di $p < 0.001$.

Tali risultati suggeriscono che queste variabili possiedono una rilevante capacità discriminante nella distinzione tra soggetti con e senza tratti dello spettro autistico all'interno del dataset analizzato. Al contrario, la variabile relativa alla compilazione del questionario da parte di un professionista sanitario non ha mostrato un'associazione statisticamente significativa con il target ($p = 0.602$).

3.4 Test V di Cramer

Per valutare l'intensità delle associazioni osservate, è stato calcolato il coefficiente V di Cramer. I risultati hanno evidenziato un'associazione moderata tra la presenza di tratti dello spettro autistico e il sesso biologico ($V = 0.410$), nonché associazioni di intensità moderata per Speech Delay/Language Disorder ($V = 0.320$), Anxiety Disorder ($V = 0.319$), Learning Disorder ($V = 0.313$) e Genetic Disorders ($V = 0.305$). La presenza di un familiare con disturbo dello spettro autistico ha mostrato un'associazione moderata-debole ($V = 0.279$), mentre l'ittero neonatale ha evidenziato un'associazione debole ($V = 0.147$).

Table 1: Risultati del test del chi-quadro e del coefficiente V di Cramer

Variabile	χ^2	p-value	b V di Cramer
Sex	331.18	<0.001	0.410
Speech Delay/Language Disorder	202.42	<0.001	0.320
Anxiety Disorder	200.34	<0.001	0.319
Learning Disorder	193.45	<0.001	0.313
Genetic Disorders	183.67	<0.001	0.305
Family member with ASD	152.96	<0.001	0.279
Jaundice	42.34	<0.001	0.147

4 Parte Teorica

4.1 Regressione Logistica

La regressione logistica è un metodo statistico utilizzato principalmente per problemi di classificazione, in particolare per stimare la probabilità che un'osservazione appartenga a una determinata categoria. A differenza della regressione lineare, che predice valori continui, la regressione logistica modella la relazione tra le variabili indipendenti e una variabile dipendente binaria (o categorica) trasformando l'output attraverso una funzione di attivazione sigmoide, che vincola i valori previsti nell'intervallo $(0, 1)$. L'equazione fondamentale per la probabilità $P(y = 1|x)$ è data da:

$$P(y = 1|x) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \dots + \beta_n x_n)}}$$

dove β_i sono i coefficienti stimati del modello. Questi parametri vengono tipicamente ottimizzati massimizzando la funzione di verosimiglianza (Maximum Likelihood Estimation - MLE) piuttosto che minimizzando l'errore quadratico.

5 Selezione delle Variabili

La selezione delle variabili (o feature selection) è un processo cruciale nell'analisi statistica e nel machine learning volto a identificare il sottoinsieme di predittori più rilevanti per costruire un modello predittivo efficace. L'obiettivo principale è migliorare le prestazioni del modello riducendo l'overfitting, accorciando i tempi di addestramento e facilitando l'interpretabilità dei risultati. Eliminare le variabili irrilevanti o ridondanti permette di ottenere un modello più robusto che generalizza meglio su dati non visti. Esistono diverse strategie per effettuare questa selezione, che si dividono principalmente in: metodi di *subset selection* (tra cui la *best subset selection* e i metodi *stepwise*), metodi di riduzione della dimensionalità (come la PCA), metodi di regolarizzazione o *shrinkage* (tra cui Ridge e Lasso) e i metodi *wrapper*. Di seguito vengono esaminati tre approcci specifici che combinano diversi metodi statistici e algoritmici.

5.1 Algoritmo Boruta

I metodi *wrapper* valutano sottoinsiemi di variabili "avvolgendo" un modello predittivo vero e proprio: il sottoinsieme viene scelto in base alla performance che produce quando viene effettivamente utilizzato per addestrare il modello, anziché in base a un criterio statistico calcolato a priori sulle singole variabili. L'algoritmo Boruta è un metodo di selezione delle variabili basato su wrapper che utilizza le Random Forest per determinare l'importanza di ogni feature in modo statisticamente rigoroso. Il principio fondamentale consiste nel creare copie "ombra" delle variabili originali, che vengono mescolate casualmente per eliminare qualsiasi relazione con la variabile target. Il modello Random Forest viene addestrato sia sulle variabili reali che su quelle ombra, e l'importanza di ciascuna viene calcolata. In ogni iterazione, le variabili reali vengono confrontate con la massima importanza delle variabili ombra; se una variabile reale ha un'importanza statisticamente superiore a quella delle ombre, viene confermata come rilevante. Al contrario, se la sua importanza è costantemente inferiore, viene scartata. Questo processo iterativo continua fino a quando tutte le variabili non vengono classificate come "importanti" o "non importanti", garantendo una selezione controllata dall'errore di Tipo I.

5.2 LASSO

Il metodo LASSO (Least Absolute Shrinkage and Selection Operator) è una tecnica di regressione che combina regolarizzazione e selezione delle variabili in un unico passaggio. In una regressione lineare classica si minimizza la somma dei quadrati degli errori; con LASSO si minimizza invece

$$\min_{\beta} \left\{ \sum_{i=1}^n (y_i - \mathbf{x}_i^T \beta)^2 + \lambda \sum_{j=1}^p |\beta_j| \right\}$$

dove il secondo termine è una penalizzazione **L1** sui coefficienti. Questa penalità ha una proprietà geometrica importante: il vincolo L1 ha forma "a rombo" nello spazio dei coefficienti, e l'intersezione tra questo vincolo e le ellissi di errore porta spesso a soluzioni in cui alcuni β_j sono **esattamente zero**. In pratica, man mano che λ aumenta, riduce le stime dei coefficienti verso lo zero, eliminando di fatto tali variabili dal modello. La

scelta di λ avviene di solito tramite ****cross-validation****, bilanciando errore di previsione e complessità del modello. È importante standardizzare le variabili prima di applicare LASSO, perché la penalizzazione agisce sui coefficienti e sarebbe influenzata dalle diverse scale delle variabili. Un limite noto è che, in presenza di forti correlazioni tra predittori, LASSO tende a selezionare solo alcune variabili del gruppo correlato, non tutte, e la scelta può essere instabile; tuttavia proprio questa aggressività nella selezione lo rende molto utile per costruire modelli parsimoniosi e interpretabili in contesti con molte variabili.

5.3 Riduzione della dimensionalità

La Factor Analysis of Mixed Data (FAMD) è una tecnica di riduzione della dimensionalità progettata per l'analisi congiunta di variabili quantitative e qualitative [3]. Dal punto di vista teorico, la FAMD può essere considerata una generalizzazione dell'Analisi delle Componenti Principali (Principal Component Analysis, PCA) e dell'Analisi delle Corrispondenze Multiple (Multiple Correspondence Analysis, MCA), poiché applica i principi della PCA alle variabili quantitative e quelli della MCA alle variabili qualitative.

A differenza dei metodi di selezione delle variabili, che mirano a identificare un sottoinsieme di predittori ritenuti rilevanti, la FAMD trasforma l'insieme originale delle variabili in un nuovo insieme di componenti latenti ortogonali, ottenute come combinazioni delle variabili originali. Le componenti sono ordinate in funzione della quantità di informazione spiegata: la prima componente cattura la quota maggiore di variabilità presente nei dati, mentre le componenti successive spiegano quote progressivamente minori di variabilità residua, mantenendo l'ortogonalità rispetto alle precedenti.


Nel contesto della modellazione predittiva, la FAMD può essere utilizzata per ridurre la dimensionalità del problema mantenendo solamente le prime componenti che sintetizzano la maggior parte dell'informazione contenuta nelle variabili originali. Tale approccio consente di ridurre la ridondanza informativa e gli effetti della multicollinearità, migliorando la stabilità numerica dei modelli e riducendo il rischio di overfitting. Tuttavia, analogamente alla PCA, la FAMD comporta una perdita di interpretabilità diretta, poiché le componenti ottenute rappresentano costrutti latenti derivati dalla combinazione delle variabili originali e non corrispondono a variabili osservabili specifiche.

Nel presente lavoro, la FAMD è stata impiegata per sintetizzare gruppi di variabili cliniche e demografiche fortemente correlate, permettendo di confrontare un approccio basato sulla riduzione della dimensionalità con approcci di selezione delle variabili quali LASSO e Boruta.


6 Modello

6.1 Modello Logistico


Il modello logistico costruito su tutte le variabili, comprese le domande del questionario, è un modello con prestazioni quasi perfette (Accuracy = 0.991, AUC = 0.9994), ma presenta evidenti problemi di separazione quasi perfetta e di instabilità dei coefficienti.



Il grafico dei residui di Pearson rispetto ai valori predetti evidenzia una forte concentrazione dei residui attorno allo zero, suggerendo una capacità classificatoria estremamente elevata del modello. Tuttavia, la presenza di alcune osservazioni con residui molto elevati e la forte polarizzazione dei valori predetti indicano un fenomeno di separazione quasi perfetta, coerente con l'inclusione nel modello di item diagnostici strettamente correlati alla variabile risposta.



Il grafico Q-Q dei residui standardizzati mostra un marcato scostamento dalla distribuzione teorica nelle code superiori. Tale comportamento è riconducibile alla presenza di osservazioni classificate con probabilità estremamente vicine a 0 o 1.




Il grafico Scale-Location evidenzia una distribuzione fortemente eterogenea dei residui standardizzati. La presenza di alcune osservazioni caratterizzate da elevata variabilità residua suggerisce che il modello produca stime estremamente accurate per la maggior parte dei soggetti, mantenendo tuttavia alcune osservazioni difficilmente classificabili.

con la maggiore importanza è risultata essere il sesso biologico, seguita dalla presenza di familiarità per ASD e da diverse condizioni cliniche e del neurosviluppo. Diversamente dal metodo LASSO, Boruta ha mantenuto simultaneamente variabili fortemente correlate tra loro, confermando il proprio comportamento di algoritmo orientato all'identificazione di tutte le caratteristiche informative piuttosto che alla costruzione di un modello parsimonioso.

Il modello di regressione logistica costruito sulle variabili selezionate mediante algoritmo Boruta ha identificato come predittori statisticamente significativi il sesso biologico, la presenza di ritardo del linguaggio e la familiarità per disturbi dello spettro autistico. L'età ha mostrato una significatività marginale ($p=0.055$). Al contrario, alcune variabili selezionate da Boruta, quali disturbi dell'apprendimento, disturbi genetici, depressione, ritardo globale dello sviluppo e problematiche comportamentali, non sono risultate statisticamente significative nel modello finale. Tale risultato riflette la filosofia dell'algoritmo Boruta, che tende a conservare tutte le variabili potenzialmente informative, anche in presenza di relazioni di dipendenza tra predittori.

Il modello Boruta ha ottenuto un'accuratezza pari al 69.3% e un valore di AUC pari a 0.742, mostrando prestazioni predittive sostanzialmente sovrapponibili a quelle ottenute mediante regressione penalizzata LASSO.



Il grafico dei residui di Pearson rispetto ai valori predetti mostra la tipica struttura osservabile nei modelli logistici binari. Non emergono pattern sistematici particolarmente rilevanti, suggerendo un adattamento soddisfacente del modello ai dati osservati.






Figure 9: Q-Q plot boruta

Il grafico Q-Q dei residui standardizzati evidenzia una buona approssimazione alla distribuzione teorica per la maggior parte delle osservazioni, con limitate deviazioni nelle code estreme. Tale comportamento è coerente con la natura discreta della variabile risposta.



Il grafico Scale-Location non evidenzia fenomeni di eterogeneità particolarmente marcati. La dispersione residua appare sostanzialmente stabile lungo il range dei valori predetti, suggerendo una buona robustezza delle stime ottenute.



L'analisi della leverage e della distanza di Cook non evidenzia la presenza di osservazioni altamente influenti. Sebbene alcune unità presentino valori di leverage relativamente elevati, nessuna osservazione sembra compromettere significativamente la stabilità del modello.

Table 2: Variabili selezionate mediante l’algoritmo Boruta

Variabile	Mean Importance	Normalized Hits	Decision
Sex	65.18	1.000	Confirmed
Family Member with ASD	25.72	1.000	Confirmed
Global Developmental Delay/Intellectual Disability	16.44	1.000	Confirmed
Speech Delay/Language Disorder	13.35	1.000	Confirmed
Anxiety Disorder	11.59	1.000	Confirmed
Depression	11.35	1.000	Confirmed
Genetic Disorders	10.05	1.000	Confirmed
Learning Disorder	8.91	1.000	Confirmed
Social Behavioural Issues	8.04	0.952	Confirmed
Age Years	6.50	0.857	Confirmed
Jaundice	-0.04	0.000	Rejected


A differenza della regressione penalizzata LASSO, l’algoritmo Boruta non effettua una selezione finalizzata alla riduzione della multicollinearità, ma ricerca tutte le variabili che contengono informazione utile rispetto alla variabile risposta. Di conseguenza, alcune variabili confermate da Boruta risultano successivamente non significative nel modello logistico a causa delle elevate correlazioni presenti tra i predittori. Nonostante ciò, il modello Boruta mantiene prestazioni predittive sostanzialmente equivalenti a quelle del modello LASSO, evidenziando come differenti strategie di selezione delle variabili possano condurre a risultati predittivi simili ma a interpretazioni sostanzialmente differenti.

6.3 Modello LASSO

L’applicazione della regressione penalizzata LASSO ha consentito di individuare un insieme ristretto di variabili predittive, riducendo automaticamente l’effetto della multicollinearità. In particolare, il modello ha selezionato età, sesso, ritardo del linguaggio, familiarità per ASD, ritardo globale dello sviluppo e alcune categorie relative alla compilazione del questionario, escludendo invece variabili fortemente correlate quali disturbi dell’apprendimento, disturbi genetici e disturbi d’ansia. Tale comportamento risulta coerente con la natura della penalizzazione L1, che tende a mantenere un numero limitato di

predittori rappresentativi dell'informazione contenuta nel dataset. Le variabili selezionate mediante regressione penalizzata LASSO sono state successivamente utilizzate per stimare un modello di regressione logistica binaria. Il modello finale ha mantenuto come predittori il sesso biologico, il ritardo del linguaggio, la familiarità per disturbo dello spettro autistico e alcune categorie relative alla compilazione del questionario. Tra le variabili selezionate, il sesso biologico e la presenza di ritardo del linguaggio hanno mostrato le associazioni statisticamente più rilevanti con la presenza di tratti dello spettro autistico, mentre l'età non è risultata statisticamente significativa.

Il modello ottenuto mediante selezione LASSO ha mostrato una buona capacità discriminante, con un'accuratezza pari al 69.3% e un'area sotto la curva ROC (AUC) pari a 0.741.



Il grafico dei residui di Pearson rispetto ai valori predetti mostra la tipica struttura a bande dei modelli logistici. Non emergono pattern sistematici particolarmente marcati, suggerendo una buona capacità del modello di rappresentare la relazione tra le variabili esplicative e la variabile risposta.

Il grafico Q-Q dei residui standardizzati evidenzia una sostanziale aderenza alla distribuzione teorica, con limitate deviazioni nelle code estreme. Tale comportamento risulta coerente con la struttura discreta della variabile risposta e con la natura del modello logistico.




Figure 10: Q-Q residuals Lasso




Figure 11: Scale Location Lasso





Figure 12: Leverage Lasso

Il grafico Scale-Location mostra una dispersione dei residui sostanzialmente costante lungo il range dei valori predetti. Sebbene il concetto di omoschedasticità non sia strettamente applicabile alla regressione logistica, il grafico non evidenzia criticità rilevanti.

L'analisi della leverage e della distanza di Cook non evidenzia la presenza di osservazioni particolarmente influenti. I valori di leverage risultano contenuti e nessuna osservazione appare in grado di compromettere la stabilità delle stime del modello



6.4 Modello FAMD

Considerata la presenza di elevata multicollinearità tra alcune variabili cliniche e la natura mista del dataset, caratterizzato dalla presenza simultanea di variabili quantitative e qualitative, è stata applicata una Factor Analysis of Mixed Data (FAMD). L'obiettivo dell'analisi non è stato quello di eliminare direttamente le variabili caratterizzate da elevata correlazione, ma di costruire nuove variabili sintetiche capaci di rappresentare i principali costrutti clinici presenti nel dataset, riducendo al contempo il problema della multicollinearità.

Table 3: Varianza spiegata dalle componenti ottenute mediante FAMD

Componente	Autovalore	% Varianza	% Cumulata
Dim.1	7.50	68.14	68.14
Dim.2	0.97	8.87	77.02
Dim.3	0.94	8.57	85.59
Dim.4	0.77	7.05	92.65
Dim.5	0.66	6.08	98.74

Table 4: Regressione logistica sulle componenti ottenute mediante FAMD

Variabile	Coefficiente	Errore standard	p-value
Intercept	0.187	0.049	<0.001
Dim.1	-0.31587	0.020	<0.001
Dim.2	0.17127	0.053	0.00122
Dim.3	-0.79265	0.05660	<0.001

Table 5: Confronto delle strategie adottate per la gestione della multicollinearità

Metodo	Approccio	Risultato
LASSO	Feature selection	Riduzione del numero di variabili
Boruta	Feature importance	Identificazione delle variabili rilevanti
FAMD	Riduzione dimensionale	Costruzione di componenti latenti

La prima componente (68.1% della varianza totale) risulta fortemente associata alle variabili Speech Delay/Language Disorder, Learning Disorder, Genetic Disorders e Anxiety Disorder, rappresentando quindi una dimensione latente interpretabile come la parte neuroevolutiva-clinica. La seconda componente (8.9% della varianza totale) risulta associata all'età, rappresentando una dimensione prevalentemente anagrafica. La terza componente (8.6% della varianza totale) appare principalmente associata alle variabili relative al sesso biologico, alla familiarità per ASD e all'ittero neonatale, configurandosi come una dimensione riconducibile ai fattori demografici e familiari.

Le componenti estratte mediante FAMD sono state successivamente utilizzate come variabili esplicative in un modello di regressione logistica binaria.




Figure 13: Residuals vs Fitted


Le componenti estratte mediante FAMD sono state successivamente utilizzate come variabili esplicative in un modello di regressione logistica binaria. I risultati hanno evidenziato una significativa capacità predittiva di tutte e 3 le componenti.

Il grafico dei residui di Pearson rispetto ai valori predetti mostra la tipica struttura a bande osservabile nei modelli di regressione logistica. Non si osservano pattern sistematici particolarmente pronunciati, suggerendo un adattamento complessivamente adeguato del modello ai dati.

Il grafico Q-Q dei residui standardizzati evidenzia una sostanziale aderenza alla distribuzione teorica, con alcune deviazioni nelle code estreme. Tali deviazioni risultano comunque compatibili con la natura discreta della variabile risposta e con la struttura del modello logistico.


Il grafico Scale-Location non evidenzia variazioni particolarmente marcate nella dispersione dei residui standardizzati lungo il range dei valori predetti. Sebbene il concetto di omoschedasticità non sia strettamente applicabile alla regressione logistica, il grafico suggerisce una sostanziale stabilità della variabilità residua.

Il grafico dei residui rispetto alla leverage non evidenzia la presenza di osservazioni fortemente influenti. I valori di leverage risultano generalmente contenuti e nessuna os-



h!

Figure 14: Q-Q FAMD



h

Figure 15: Scale Location FAMD




Figure 16: Leverage FAMD

servazione supera le soglie associate alla distanza di Cook, suggerendo l'assenza di punti influenti in grado di compromettere la stabilità delle stime.

7 Conclusioni

Il confronto tra il modello costruito utilizzando il dataset completo e i modelli ottenuti a partire dal dataset ridotto, privato delle variabili derivanti dai questionari diagnostici, ha evidenziato la presenza del fenomeno di data leakage. In particolare, le variabili relative agli strumenti di screening e valutazione clinica dell'autismo (quali punteggi aggregati e scale diagnostiche) risultano fortemente correlate con la variabile risposta, poiché rappresentano esse stesse misure direttamente utilizzate nel processo diagnostico. L'inclusione di tali informazioni all'interno del modello comporta un incremento artificiale delle prestazioni predittive, determinando una sovrastima della capacità di generalizzazione del modello e limitandone l'utilità nell'identificazione di nuovi fattori associati ai tratti dello spettro autistico.

Per tale ragione, nonostante l'elevatissima accuratezza ottenuta dal modello completo, l'analisi è stata successivamente condotta sul dataset ridotto, con l'obiettivo di individuare

variabili cliniche, demografiche e familiari in grado di contribuire alla classificazione dei soggetti senza ricorrere direttamente agli strumenti diagnostici utilizzati per la definizione dell'esito stesso.

L'applicazione dei tre differenti approcci di selezione e riduzione delle variabili ha permesso di evidenziare come strategie metodologicamente differenti possano produrre modelli caratterizzati da prestazioni predittive simili ma da proprietà interpretative differenti. In particolare, l'analisi ha consentito di individuare sia un insieme ristretto di variabili altamente informative, sia dimensioni latenti in grado di sintetizzare efficacemente la struttura informativa del dataset.

Complessivamente, il modello ottenuto mediante regressione penalizzata LASSO rappresenta il miglior compromesso tra capacità predittiva, interpretabilità e parsimonia. Pur mostrando prestazioni leggermente inferiori rispetto al modello logistico completo, il LASSO consente di ridurre significativamente la dimensionalità del problema, eliminando automaticamente numerose variabili fortemente correlate e mantenendo un numero limitato di predittori caratterizzati da elevata capacità discriminante. Tale approccio si è dimostrato particolarmente efficace nel contesto analizzato, caratterizzato da un'elevata presenza di multicollinearità.

A differenza del LASSO, l'algoritmo Boruta non mira alla riduzione della multicollinearità, ma all'identificazione di tutte le variabili contenenti informazione utile rispetto alla variabile risposta. Di conseguenza, alcune variabili confermate da Boruta risultano successivamente non significative all'interno del modello logistico a causa delle forti correlazioni presenti tra i predittori. Nonostante ciò, il modello costruito sulle variabili selezionate da Boruta ha mantenuto prestazioni predittive sostanzialmente equivalenti a quelle ottenute mediante LASSO, evidenziando come differenti strategie di selezione possano condurre a risultati predittivi comparabili pur producendo interpretazioni sostanzialmente differenti del fenomeno studiato.

L'approccio basato sulla Factor Analysis of Mixed Data (FAMD) ha consentito di affrontare il problema della multicollinearità mediante la costruzione di componenti latenti, sintetizzando l'informazione contenuta nelle variabili originali in un numero ridotto di dimensioni non correlate. L'interpretazione delle componenti estratte ha permesso di identificare tre principali dimensioni latenti: una componente neuroevolutiva-clinica, una

componente anagrafica e una componente biologico-familiare. Sebbene il modello costruito sulle componenti FAMD presenti una capacità predittiva leggermente inferiore rispetto ai modelli basati sulla selezione diretta delle variabili, esso offre un importante vantaggio interpretativo, consentendo di individuare costrutti latenti potenzialmente rilevanti nel processo diagnostico dei disturbi dello spettro autistico.

Sebbene i modelli costruiti mediante LASSO, Boruta e FAMD abbiano mostrato prestazioni predittive sostanzialmente comparabili, l'approccio basato sulla riduzione della dimensionalità mediante Factor Analysis of Mixed Data è risultato particolarmente interessante rispetto agli obiettivi del presente lavoro. A differenza dei metodi di selezione delle variabili, la FAMD ha consentito non solo di gestire efficacemente il problema della multicollinearità, ma anche di identificare un numero limitato di componenti latenti clinicamente interpretabili, sintetizzando l'informazione contenuta nelle variabili originali senza eliminarla direttamente.

In particolare, l'analisi ha evidenziato l'esistenza di tre principali dimensioni latenti associate alla classificazione dei soggetti: una componente neuroevolutiva-clinica, una componente anagrafica e una componente biologico-familiare. La capacità di identificare tali costrutti latenti, mantenendo al contempo una capacità predittiva sostanzialmente equivalente a quella ottenuta mediante gli approcci di selezione delle variabili, suggerisce che la riduzione della dimensionalità rappresenti, nel contesto specifico analizzato, l'approccio metodologicamente più coerente con gli obiettivi della ricerca.

Relativamente alla domanda di ricerca, i risultati ottenuti suggeriscono che la classificazione dei soggetti con tratti dello spettro autistico non dipenda da un singolo fattore isolato, ma sia piuttosto associata alla presenza di differenti dimensioni latenti che sintetizzano aspetti del neurosviluppo, demografici e familiari [4]. In particolare, la componente clinica, comprendente ritardo del linguaggio, disturbi dell'apprendimento, disturbi genetici, problematiche comportamentali e comorbidità psicologiche, è risultata rappresentare il principale costrutto associato alla classificazione dei soggetti. Parallelamente, fattori anagrafici e biologico-familiari, quali età, sesso e familiarità per disturbi dello spettro autistico, hanno mostrato un contributo statisticamente significativo.

Sebbene la natura osservazionale del dataset non consenta di formulare conclusioni causali, i risultati suggeriscono che l'impiego di tecniche di riduzione della dimension-

alità possa rappresentare uno strumento utile per l'identificazione di dimensioni latenti potenzialmente rilevanti nel processo diagnostico dei disturbi dello spettro autistico, contribuendo a una migliore comprensione della struttura sottostante ai dati clinici e comportamentali.

Table 6: Confronto tra i modelli stimati

Modello	Accuracy	AUC	N. variabili	Approccio
Modello completo	0.991	0.999	27	Overfitting diagnostico
LASSO	0.693	0.741	6	Selezione penalizzata
Boruta	0.693	0.742	10	Conservazione dell'informazione
FAMD	0.682	0.725	3 componenti	Riduzione dimensionale

References

References

- [1] American Psychiatric Association. *Diagnostic and Statistical Manual of Mental Disorders*. 5th ed. Washington, DC: American Psychiatric Publishing, 2013.
- [2] Embrace Autism. *AQ-10: Autism Spectrum Quotient*. Accessed: 2026-07-06. 2024. URL: <https://embrace-autism.com/aq-10/>.
- [3] Alboukadel Kassambara. *FAMD: Factor Analysis of Mixed Data in R — Essentials*. Accessed: 2026-07-06. 2024. URL: <https://www.sthda.com/english/articles/31-principal-component-methods-in-r-practical-guide/115-famd-factor-analysis-of-mixed-data-in-r-essentials/#visualization-and-interpretation>.
- [4] Meng-Chuan Lai et al. “Towards Understanding Sex Differences in Autism Spectrum Disorder”. In: *Journal of Child Psychology and Psychiatry* 56.6 (2015). Accessed: 2026-07-06, pp. 631–662. URL: <https://research.monash.edu/>

en/publications/towards-understanding-sex-differences-in-autism-spectrum-disorder/.

- [5] Madhuri Uppuluri. *Dataset*. Accessed: 2026-07-06. 2023. URL: <https://www.kaggle.com/datasets/uppulurimadhuri/dataset>.